

Unidade 1 – Conceitos Básicos de Séries Temporais

Uma série temporal é uma sequência de dados pontos coletados ou registrados ao longo do tempo, geralmente em intervalos uniformes. Cada ponto na série representa o valor de uma variável medida em um momento específico. Esses dados são usados para analisar como a variável evolui ao longo do tempo, identificar padrões e fazer previsões futuras. Séries temporais são amplamente aplicadas em diversas áreas, como economia, finanças, climatologia, entre outras.

Características Principais de Séries Temporais

1. Sequência Cronológica:

- ✓ Os dados são organizados em ordem temporal, sendo essencial que a sequência dos pontos respeite a cronologia dos eventos.

2. Intervalos de Tempo Uniformes:

- ✓ As observações são coletadas em intervalos regulares, como diariamente, semanalmente, mensalmente etc.

3. Dependência Temporal:

- ✓ Os valores da série temporal podem ser autocorrelacionados, ou seja, o valor em um ponto no tempo pode depender dos valores em pontos anteriores.

Objetivos da Análise de Séries Temporais

1. **Descrever Dados:** Identificar e descrever padrões de tendência, sazonalidade e ciclos.
2. **Previsão:** Usar dados históricos para prever valores futuros.
3. **Deteção de Anomalias:** Identificar comportamentos inesperados ou fora do padrão.
4. **Controle e Ajuste:** Monitorar e ajustar processos com base em dados temporais.

Componentes das Séries Temporais

1. Tendência (Trend):

- ✓ Movimento de longo prazo na série que mostra uma direção geral, seja crescente, decrescente ou estável.

2. **Sazonalidade (Seasonality):**

- ✓ Padrões ou flutuações que se repetem em intervalos regulares, como ciclos diários, mensais ou anuais.

3. **Ciclos (Cycles):**

- ✓ Flutuações de longo prazo causadas por fatores econômicos ou outros, que não possuem uma periodicidade fixa.

4. **Ruído (Noise):**

- ✓ Variabilidade aleatória que não pode ser explicada por tendência, sazonalidade ou ciclos. Representa a parte imprevisível dos dados.

Exemplos de Séries Temporais

1. **Econômicas:** Preços de ações, taxa de desemprego, PIB trimestral, taxas de câmbio
2. **Financeiras:** Receita mensal de uma empresa, vendas diárias de um produto.
3. **Climatológicas:** Temperatura diária, níveis de precipitação mensal.
4. **Demográficas:** População anual, taxas de natalidade e mortalidade.
5. **Vendas:** Vendas diárias ou mensais de produtos.
6. **Tráfego:** Número de visitantes em um site ao longo do tempo

Métodos de Análise de Séries Temporais

1. **Modelos ARIMA (Autoregressive Integrated Moving Average):**

- ✓ Usados para modelar e prever séries temporais, especialmente úteis para séries não estacionárias.

2. **Decomposição:**

- ✓ Técnica para separar uma série temporal nos seus componentes (tendência, sazonalidade e ruído).

3. **Suavização Exponencial:**

- ✓ Métodos como Holt-Winters que capturam tanto a tendência quanto a sazonalidade nos dados.

4. **Análise de Fourier:**

- ✓ Utilizada para identificar frequências dominantes e padrões periódicos na série.

Aplicações de Séries Temporais

- **Previsão de Vendas:** Utilizar dados históricos para prever futuras vendas e ajustar a produção.
- **Análise Financeira:** Avaliar tendências de mercado e tomar decisões de investimento.
- **Meteorologia:** Prever condições climáticas com base em dados históricos.
- **Planejamento de Recursos:** Estimar a demanda futura para otimizar a alocação de recursos.

Ferramentas e Softwares

- **R:** Pacotes como forecast, tseries, e zoo são amplamente utilizados.
- **Python:** Bibliotecas como pandas, statsmodels, prophet e matplotlib.
- **Excel:** Funções de análise de dados e gráficos.

Estacionariedade

A estacionariedade é um conceito fundamental em séries temporais, referindo-se a uma série cujas propriedades estatísticas, como a média e a variância, são constantes ao longo do tempo. Analisar e garantir a estacionariedade é crucial porque muitos métodos de análise e previsão de séries temporais, como os modelos ARIMA, assumem que os dados são estacionários.

Características da Estacionariedade

Uma série temporal é considerada estacionária se satisfizer as seguintes condições:

1. Média Constante:

- ✓ A média da série não muda ao longo do tempo.
- ✓ $E[X_t] = \mu$ para todo t (o valor médio esperado para a variável em estudo é constante para todo o tempo)

2. Variância Constante:

- ✓ A variabilidade dos dados em torno da média é constante ao longo do tempo.
- ✓ $Var(X_t) = \sigma^2$ para todo t

3. **Covariância Constante:**

- ✓ A covariância entre dois pontos na série depende apenas do intervalo entre eles, não do tempo específico em que são medidos.
- ✓ $Cov(X_t, X_{t+h}) = \gamma(h)$ para todo t

Tipos de Estacionariedade

1. **Estacionariedade Estrita:**

- ✓ Uma série é estritamente estacionária se a distribuição conjunta de qualquer subconjunto de valores da série é a mesma, independentemente de quando a amostra é tomada.

2. **Estacionariedade Fraca:**

- ✓ Uma série é estacionária em sentido amplo se a média, a variância e a covariância são constantes ao longo do tempo. Este é o tipo de estacionariedade mais frequentemente utilizado na prática.

Testes para Estacionariedade

Existem vários testes estatísticos para verificar a estacionariedade de uma série temporal:

1. **Teste de Dickey-Fuller Aumentado (ADF):**

- ✓ Testa a presença de uma raiz unitária na série temporal. A hipótese nula do teste é que a série tem uma raiz unitária (não é estacionária).

2. **Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin):**

- ✓ Testa a hipótese nula de que a série é estacionária em torno de uma média ou tendência linear.

3. **Teste de Phillips-Perron:**

- ✓ Semelhante ao ADF, testa a presença de uma raiz unitária, mas ajusta para a autocorrelação e heterocedasticidade nos resíduos.

Transformações para Estacionariedade

Se uma série não é estacionária, várias transformações podem ser aplicadas para torná-la estacionária:

1. Diferença (Differencing):

- ✓ Subtrair cada valor da série pelo valor anterior. Esta é a técnica mais comum para remover tendência.
- ✓ $Y_t = X_t - X_{t-1}$

2. Transformação Logarítmica:

- ✓ Usada para estabilizar a variância.
- ✓ $Y_t = \log(X_t)$

3. Suavização (Smoothing):

- ✓ Técnicas como médias móveis podem ser aplicadas para suavizar flutuações de curto prazo.

Exemplos

- **Exemplo Não Estacionário:** Uma série temporal que apresenta uma tendência ascendente ou descendente ao longo do tempo, como o PIB de um país ao longo de décadas.
- **Exemplo Estacionário:** Dados de temperatura diários que flutuam em torno de uma média constante sem uma tendência de longo prazo.

Importância da Estacionariedade

- **Modelagem e Previsão:** Muitos modelos estatísticos, como ARIMA, requerem dados estacionários para produzir previsões precisas.
- **Análise de Componentes:** Facilita a separação dos componentes da série temporal, como tendência e sazonalidade.

Função de Autocorrelação

A função de autocorrelação é uma ferramenta estatística usada para medir o grau de correlação entre valores de uma série temporal em diferentes pontos no tempo. Ela é essencial para identificar a dependência temporal nos dados, o que é fundamental para a modelagem e previsão de séries temporais.

Definição

A autocorrelação de uma série temporal X_t em uma defasagem h (também chamada de lag) é a correlação entre X_t e X_{t+h} . A função de autocorrelação (FAC), denotada por $\rho(h)$ é definida como:

$$\rho(h) = \frac{E[(X_t - \mu)(X_{t+h} - \mu)]}{\sigma^2}$$

em que: μ é a média da série temporal; σ^2 é a variância da série temporal; E denota o valor esperado.

Interpretação

- **Autocorrelação Positiva:** Indica que altos valores em X_t tendem a ser seguidos por altos valores em X_{t+h} , e baixos valores tendem a ser seguidos por baixos valores.
- **Autocorrelação Negativa:** Indica que altos valores em X_t tendem a ser seguidos por baixos valores em X_{t+h} , e vice-versa.
- **Autocorrelação Zero:** Indica que não há dependência linear entre X_t e X_{t+h} .

Função de Autocorrelação Parcial (FACP)

A função de autocorrelação parcial mede a correlação entre X_t e X_{t+h} removendo o efeito das autocorrelações para lags menores que h . É útil para identificar o número adequado de lags a serem incluídos em modelos autoregressivos (AR).

Gráfico da Função de Autocorrelação (ACF)

O gráfico da função de autocorrelação, ou correlograma, é uma ferramenta visual que exibe a autocorrelação $\hat{\rho}(h)$ em diferentes defasagens h . Ele ajuda a identificar padrões, sazonalidades e o grau de dependência temporal.

Exemplos de Uso

- **Identificação de Modelos ARIMA:** A ACF e a PACF são usadas para determinar os parâmetros de ordem dos modelos ARIMA.
- **Detecção de Sazonalidade:** Padrões repetitivos na ACF podem indicar a presença de sazonalidade nos dados.
- **Validação de Modelos:** Analisar os resíduos de um modelo ajustado para verificar se eles são ruído branco (sem autocorrelação significativa).

Ferramentas para Cálculo e Visualização

- **Python:** A biblioteca statsmodels oferece funções como `acf` e `pacf` para calcular e plotar a função de autocorrelação.
- **R:** O pacote `forecast` fornece funções como `Acf` e `Pacf` para análise de autocorrelação.
- **Excel:** Análise de dados pode ser feita usando funções incorporadas e add-ins específicos para séries temporais.

Modelos no Domínio do Tempo e da Frequência

A análise de séries temporais pode ser realizada tanto no domínio do tempo quanto no domínio da frequência. Cada abordagem oferece insights diferentes e complementares sobre os dados.

Modelos no Domínio do Tempo

Os modelos no domínio do tempo analisam a relação entre os valores da série temporal ao longo do tempo. Os principais modelos incluem:

1. Modelos AR (Autoregressive):

Baseiam-se na suposição de que os valores passados da série têm uma influência linear nos valores futuros.

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t$$

em que: c é uma constante, ϕ_i são os coeficientes autoregressivos, p é a ordem do modelo e ε_t é o termo de erro (ruído branco).

2. Modelos MA (Moving Average):

Modelam a série como uma função linear de erros passados.

$$Y_t = \mu + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

em que: θ_j são os coeficientes de média móvel, μ é a média da série (quando a série é estacionária), q é a ordem do modelo; ε_t é o termo de erro.

3. Modelos ARMA (Autoregressive Moving Average):

E a combinação das abordagens AR e MA.

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

4. Modelos ARIMA (Autoregressive Integrated Moving Average):

Extensão dos modelos ARMA para séries não estacionárias, incluindo uma componente de diferenciação

$$(1 - B)^d Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

em que: $(1 - B)^d Y_t$ representa a série temporal Y_t diferenciada d vezes; c é o termo constante, ϕ_i são os coeficientes da parte autoregressiva (AR); θ_i são os coeficientes da parte de média móvel (MA), ε_t são os termos de erro branco.

5. Modelos SARIMA (Seasonal ARIMA):

Extensão dos modelos ARIMA para capturar sazonalidades

$$\left(1 - \sum_{i=1}^p \phi_i B^i\right) \left(1 - \sum_{j=1}^p \Phi_j B^{js}\right) (1 - B)^d (1 - B^s)^D Y_t = c + \left(1 - \sum_{i=1}^q \theta_i B^i\right) \left(1 - \sum_{k=1}^q \Theta_k B^{ks}\right) \varepsilon_t$$

em que: ϕ_i coeficientes autorregressivos não sazonais; Φ_j são os coeficientes autoregressivos sazonais; θ_i são os coeficientes de média móvel não sazonais; Θ_k são os coeficientes de média móvel sazonais; B operador de defasagem; d ordem de diferenciação não sazonal; D ordem de diferenciação sazonal; s período sazonal, ε_t termos de erro branco (ruído).

6. Modelos de Alisamento Exponencial:

Aplicam pesos decrescentes exponencialmente para dados passados. Esses modelos são úteis para fazer previsões de curto prazo, especialmente quando os dados apresentam flutuações sem grandes mudanças estruturais.

Método de Holt-Winters:

⇒ **Alisamento Simples:** para séries sem tendência ou sazonalidade.

$$F_{t+1} = \alpha y_t + (1 - \alpha) F_t$$

em que: F_{t+1} previsão para o próximo período; y_t valor observado no período atual; F_t previsão no período atual; α fator de suavização

⇒ **Alisamento com Tendência (Holt):** para séries com tendência

$$F_{t+h} = L_t + hT_t$$

$$L_t = \alpha y_t + (1 - \alpha)(L_{t-1} + T_{t-1})$$

$$T_t = h[\beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1}]$$

em que: L_t o nível estimado (valor médio ou ponto central da série); T_t tendência estimada; β fator de suavização da tendência; F_{t+h} previsão para h períodos a frente

⇒ **Alisamento com Tendência e Sazonalidade (Holt-Winters)**: para séries com tendência e sazonalidade.

$$F_{t+h} = (L_t + hT_t)S_{t+h-p}$$

$$L_t = \alpha \frac{y_t}{S_{t-p}} + (1 - \alpha)(L_{t-1} + T_{t-1})$$

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1}$$

$$S_t = \gamma \frac{y_t}{L_t} + (1 - \gamma)S_{t-p}$$

em que: S_t componente sazonal estimado; γ fator de suavização sazonal; p é o período sazonal; L_t o nível estimado; T_t tendência estimada; β fator de suavização da tendência; F_{t+h} previsão para h períodos a frente

Modelos no Domínio da Frequência

Os modelos no domínio da frequência analisam a série temporal em termos de suas componentes frequenciais, utilizando transformações como a Transformada de Fourier. Os principais conceitos incluem:

1. Análise de Fourier:

Decompõe uma série temporal em uma soma de senóides e cossenoides de diferentes frequências.

$$Y(f) = \sum_{t=0}^{n-1} Y_t e^{-2\pi i f t / n}$$

em que: $Y(f)$ representa a amplitude da frequência f .

2. Espectro de Frequência:

Mostra a amplitude ou potência das diferentes frequências presentes na série temporal. É útil para identificar ciclos e padrões periódicos nos dados.

3. Análise de Ondaletas (Wavelet Analysis):

Decompõe a série temporal em componentes de frequência e tempo simultaneamente, permitindo a análise de variações locais em diferentes escalas.

$$w(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} X(t) \psi^* \left(\frac{t - b}{a} \right) dt$$

em que: ψ é a função de ondaleta, a é a escala e b é a posição no tempo.

Aplicações Práticas

Domínio do Tempo

- **Modelos ARIMA** são amplamente usados em previsões de séries temporais, como vendas, estoque e indicadores econômicos.
- **Modelos SARIMA** são usados para séries com componentes sazonais, como consumo de energia elétrica e temperatura.

Domínio da Frequência

- **Análise de Fourier** é usada para identificar padrões cíclicos em dados financeiros, como ciclos econômicos.
- **Análise de Ondaletas** é útil em estudos de sinais biomédicos e geofísicos, onde as variações locais e a análise multi-resolução são importantes.