

Disciplina:

# SÉRIES TEMPORAIS

Professora: Patrícia de Sousa Ilambwetsi

Bacharel em Estatística pela UFOP

Mestre em Estatística pela UFV

Doutora em Estatística pela UFV

Especialista em Ciências de Dados e Big Data pela PUC Minas



# Roteiro

## Unidade 3 – Modelagem de Séries temporais Estacionárias

### 3.1 Modelo Autoregressivo e de Médias Móveis (ARMA)

- Componente autoregressivo (AR)
- Componente de médias móveis (MA)
- Estrutura do modelo ARMA
- Pressuposições
- Ajuste do modelo
- Refinamento do Modelo
- Previsão
- Vantagem
- Desvantagem

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

A modelagem de séries temporais pelo modelo autoregressivo e de médias móveis (ARMA) é uma técnica estatística amplamente utilizada para analisar e prever valores futuros com base em dados temporais passados.

O modelo ARMA combina dois componentes principais:

⇒ AR (Autoregressivo): modela a série temporal como uma combinação linear de seus valores defasados

⇒ MA (Média Móvel): modela a série temporal como uma média ponderada dos erros passados (resíduos).

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Componente Autoregressivo (AR)

Modela o valor atual da série como uma combinação linear de valores passados permitindo capturar dependências temporais, padrões de persistência e outras características dinâmicas na série.

Em um modelo AR de ordem  $p$ , o valor atual da série  $Y_t$  é explicado como uma soma ponderada dos  $p$  valores anteriores mais um termo de erro  $\varepsilon_t$  (ruído branco).

- A equação básica do modelo  $AR(p)$  é

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

em que:  $Y_t$  o valor da série no tempo  $t$ ;  $c$  é uma constante;  $\phi_1, \dots, \phi_p$  coeficientes do modelo que medem a influência dos valores passados;  $\varepsilon_t$  termo de erro sem autocorrelação com média zero e variância constante (ruído branco).

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ **Componente Autoregressivo (AR)**

**Interpretação do coeficiente  $\phi$ :** cada coeficiente  $\phi_i$  mede a contribuição do valor defasado  $Y_{t-i}$  para o valor atual  $Y_t$  com  $i = 1, \dots, p$

- **Para  $\phi_i$  positivo:** altos valores de  $Y_{t-i}$  tendem a gerar altos valores para  $Y_t$
- **Para  $\phi_i$  negativo:** altos valores de  $Y_{t-1}$  tendem a gerar baixos valores para  $Y_t$

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ **Componente Autoregressivo (AR)**

#### Estruturas identificadas

**Dependência Temporal:** detecta e captura a dependência temporal nos dados, ou seja, a forma como os valores passados influenciam os valores futuros.

**Padrões de Persistência:** detecta padrões persistentes na série temporal.

**Oscilações ou Ciclos:** captura autocorrelação sazonal significativa, ou seja, oscilações de valores passados que correlacionam significativamente com os valores atuais

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ **Componente Autoregressivo (AR)**

#### Exemplo Prático:

Imagine uma série temporal que mede as vendas diárias de um produto.

Suponha que as vendas de um dia estão fortemente correlacionadas com as vendas do dia anterior.

O modelo AR é capaz de capturar essa relação e fazer a previsão das vendas de hoje baseado nas altas vendas do dia anterior.

**OBS:** Em um modelo ARMA(1,0), se o coeficiente AR é 0,7, isso significa que 70% do valor atual da série é explicado pelo valor imediatamente anterior.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Componente Média Móvel (MA)

Modela a dependência entre o valor atual da série temporal e os erros (resíduos) das observações passadas.

Em um modelo MA ordem  $q$ , o valor atual da série  $Y_t$  é representado como uma média ponderada dos  $q$  erros passados (ou choques) mais um termo de erro  $\varepsilon_t$ .

- A equação básica do modelo  $MA(q)$  é

$$Y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

em que:  $Y_t$  o valor da série no tempo  $t$ ;  $c$  é uma constante;  $\theta_1, \dots, \theta_q$  coeficientes do modelo MA que medem a influência dos erros passados sobre o valor atual;  $\varepsilon_t$  termo de erro no tempo  $t$  sem autocorrelação com média e variância zero (ruído branco);  $\varepsilon_{t-q}$  são os erros passados (ruído branco).



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ **Componente Média Móvel (MA)**

**Interpretação do coeficiente  $\theta$ :** cada coeficiente  $\theta_i$  reflete o impacto que o erro  $\varepsilon_{t-i}$  no tempo  $t - i$  tem sobre o valor atual  $Y_t$  em que  $i = 1, \dots, q$

- **Para  $\theta_i$  positivo:** indica que um erro positivo no período anterior tende a aumentar o valor atual de  $Y_t$
- **Para  $\theta_i$  negativo:** indica que um erro positivo no período anterior tende a diminuir o valor atual de  $Y_t$

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ **Componente Média Móvel (MA)**

#### Estruturas identificadas

**Efeito dos Choques Passados:** captura a influência dos choques ou erros passados na série.

**Ruído e Ajustes Futuros:** ajusta flutuações permitindo que o modelo suavize o impacto dos erros passados nos valores atuais.

**Oscilações de Curto Prazo:** é eficaz na modelagem de oscilações de curto prazo e efeitos temporários que não persistem por muitos períodos, mas afetam a série de maneira significativa.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Componente Média Móvel (MA)

#### Exemplo Prático:

Suponha uma série temporal de preços de um produto.

Se uma notícia ou um evento inesperado fez o preço subir ontem, o modelo MA pode ajustar a influência desse erro na previsão de hoje.

**OBS:** Para ARMA(0,1), se o coeficiente MA é -0,5, isso significa que o valor atual da série é influenciado pelo erro do período anterior de maneira inversa, com o impacto do erro sendo reduzido em 50%.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Estrutura do Modelo ARMA

O modelo ARMA é a combinação do componente AR(p) e MA (q) denotado por:

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

em que  $p$  é a ordem do componente autoregressivo (AR) e  $q$  é a ordem do componente de média móvel (MA).

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Pressuposições do Modelo ARMA

- **Estacionariedade:** exige que a média, a variância e a autocorrelação sejam constantes ao longo do tempo.

**Implicações:** para série não estacionária, o modelo pode estimar parâmetros inconsistentes e previsões não confiáveis. Neste caso, aplicar a transformação de diferenciação na série.

- **Linearidade:** assume uma relação linear entre os valores e erros passados com o valor atual da série

**Implicações:** relações não lineares, o modelo pode não capturar corretamente a dinâmica dos dados, resultando em previsões menos precisas.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Pressuposições do Modelo ARMA

- **Dependência Temporal:** assume a existência de uma dependência temporal na série em que os valores passados influenciam os valores futuros.

**Implicações:** a dependência temporal não significativa invalida o modelo ARMA implicando no uso de um modelo mais simples como a média móvel simples

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Ajuste do Modelo ARMA

O ajuste de um modelo ARMA (AutoRegressive Moving Average) é fundamental na análise de séries temporais para capturar o comportamento dos dados e fazer previsões.

**Etapas a seguir:**

- 1) Verificação da Estacionariedade
- 2) Identificação do modelo
- 3) Estimação dos parâmetros
- 4) Validação do Modelo

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)


⇒ Ajuste do Modelo ARMA

#### 1) Verificação Estacionariedade


**Visualização gráfica:** a estacionariedade no gráfico da série temporal no domínio do tempo implica que as propriedades estatísticas da série tais como: a média, a variância e a correlação, são constantes ao longo do tempo.



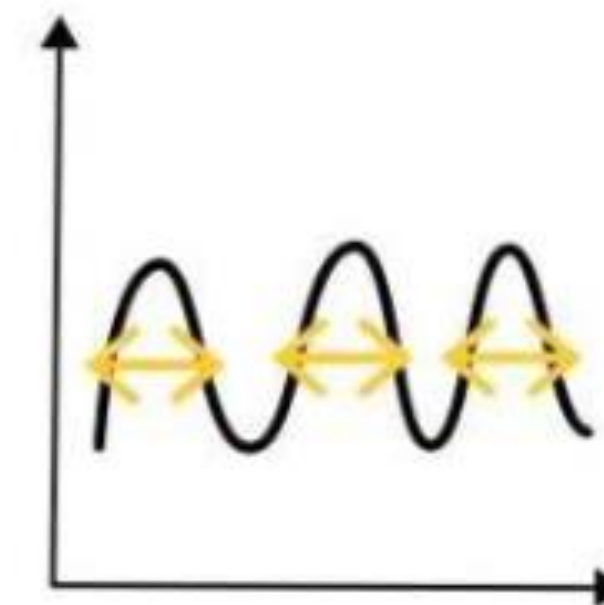
Gráfico de uma série temporal estacionária: média, variância e covariância constante ao longo do tempo



Mean independent on time




Variance independent on time




Covariance independent on time


Gráfico de uma série temporal não estacionária: média, variância e covariância não constante ao longo do tempo



Mean dependent on time



Variance dependent on time



Covariance dependent on time

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 1) Verificação Estacionariedade

**Teste de Raiz Unitária:** Testes como o Teste de Dickey-Fuller aumentado (ADF) são usados para verificar a presença de raiz unitária, o que indica não estacionariedade

Hipóteses:

$H_0$ : Presença de raiz unitária na série temporal indicando que a média dos dados não está estacionária.

$H_1$ : Não presença de raiz unitária na série temporal indicando que a média dos dados está estacionária.

**$pvalor < \alpha$  (nível de significância de 5%) rejeita-se  $H_0$**

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 1) Verificação Estacionariedade

**Transformações:** para série não estacionária aplique transformações como diferenciação ou transformação logarítmica

**Diferenciação:** usada principalmente para remover tendências ou sazonalidades

**Logarítmica:** serve para estabilizar a variância e o crescimento exponencial da série ao longo do tempo

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 2) Identificação do modelo

Consiste em identificar a estrutura do modelo, ou seja, conhecer os valores dos parâmetros  $p$  e  $q$

- **Função de Autocorrelação (ACF)**

A ACF mede a correlação entre a série temporal e suas defasagens.

Picos significativos na ACF determinam a ordem do componente  $q$  do modelo MA

- **Função de Autocorrelação Parcial (PACF)**

A PACF mede a correlação pontual entre a série e suas defasagens

Picos significativos na PACF identificam a ordem do componente  $p$  do modelo AR

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

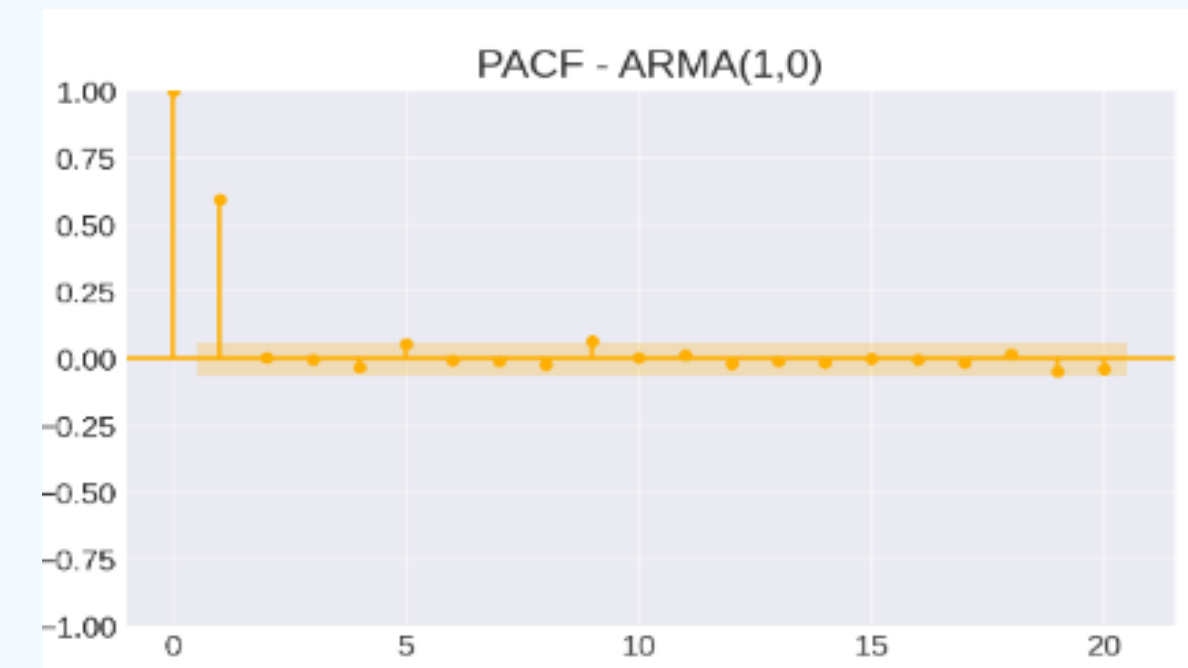
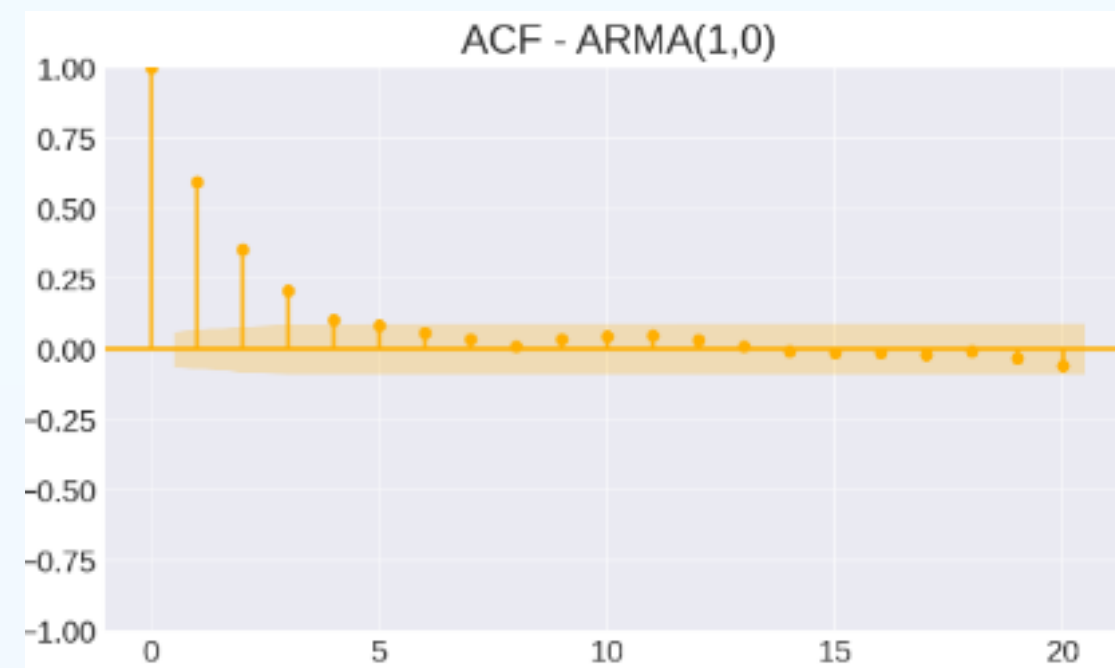
⇒ Ajuste do Modelo ARMA

#### 2) Identificação do modelo

- Definição do termo do Modelo Autoregressivo (AR)

**ACF:** Mostra um decaimento exponencial ou oscilatório

**PACF:** Exibe um corte abrupto após a primeira defasagem, indicando a presença de um único termo AR.



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)


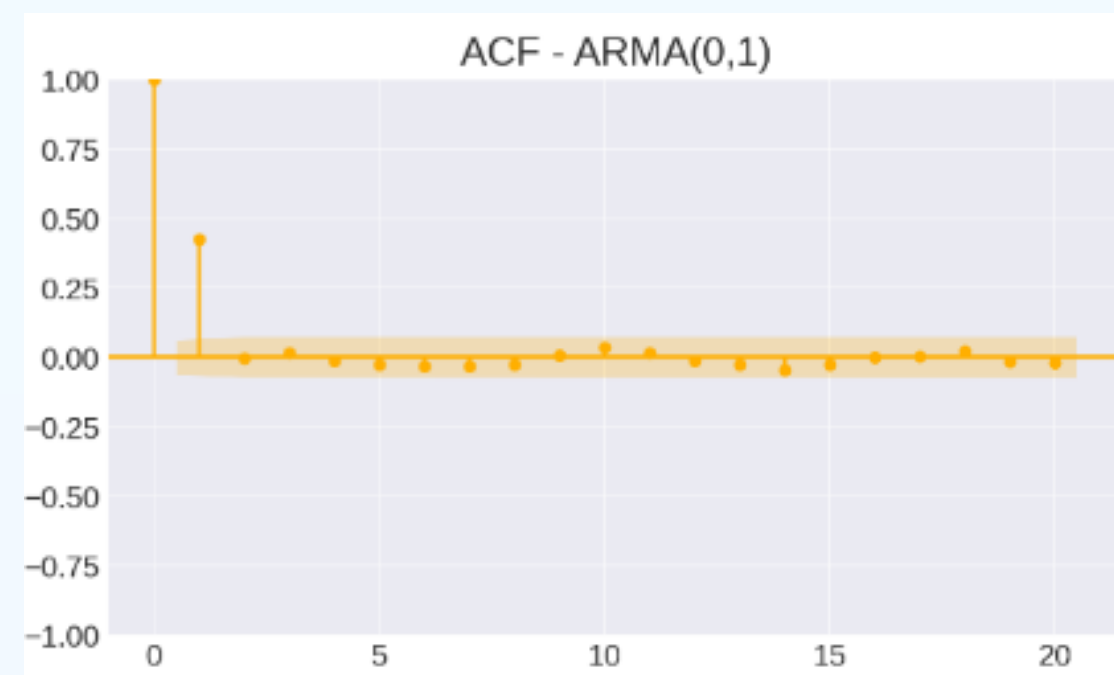
⇒ Ajuste do Modelo ARMA

#### 2) Identificação do modelo

- Definição do termo do Modelos de Média Móveis (MA)

**ACF:** Exibe um corte abrupto após a primeira defasagem

**PACF:** Mostra um decaimento exponencial ou oscilatório, o que é esperado para modelos MA.



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)



⇒ Ajuste do Modelo ARMA

#### 2) Identificação do modelo

- Definição dos termos do Modelo Autoregressivo (AR) e de Média Móveis (MA)

**ACF:** Apresenta um padrão mais complexo, com decaimento menos pronunciado, devido à combinação dos termos AR e MA

**PACF:** exibe um padrão misto, sem corte abrupto, refletindo a interação dos componentes AR e MA





## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 3) Estimação dos parâmetros

##### Método de Máxima Verossimilhança

Estima valores para  $\phi$  (parâmetros AR) e  $\theta$  (parâmetros MA) que maximizam a função de verossimilhança da série temporal observada, ou seja, determinam parâmetros que descrevem as melhores suposições para o verdadeiro comportamento da série.

$$L(\theta|X) = \prod_{i=1}^n f(x_i|\theta)$$

sendo  $f()$  a função densidade de probabilidade



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

Formas de validar a qualidade do modelo ajustado aos dados

- Critérios de Informação
- Análise dos Resíduos

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

- Critérios de Informação

**AIC (Akaike Information Criterion):** é uma medida usada para comparar a qualidade do ajuste (quão bem o modelo se ajusta aos dados) quanto a complexidade de diferentes modelo (número de parâmetros).

$$AIC = 2k - 2\ln(L)$$

sendo  $k$  é o número de parâmetros e  $L$  a função de verossimilhança

**Interpretação:** o modelo com o menor valor de AIC é considerado o melhor.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

- Critérios de Informação

**BIC (Bayesian Information Criterion):** considera a qualidade do ajuste e a complexidade do modelo, mas aplica uma penalização mais forte para modelos com mais parâmetros. É utilizado para grandes tamanhos de amostras.

$$BIC = \ln(n)k - 2\ln(L)$$

sendo  $K$  é o número de parâmetros,  $L$  a função de verossimilhança e  $n$  tamanho da amostra.

**Interpretação:** o modelo com o menor valor de BIC é considerado o melhor.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

- Critérios de Informação

	AIC	BIC
Amostra	Pequena	Grande
Complexidade (evitar overfitting)	Penaliza menos	Penaliza mais
Objetivo	Previsão	Estrutura
Seleção	Modelo Complexo	Modelo Simples

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

Resíduos: Diferença entre os valores observados e os valores ajustados pelo modelo

- Análise dos Resíduos

**Resíduos:** Verificar se os resíduos do modelo ajustado se comportam como ruído branco

- Média zero
- Variância constante (Homoscedasticidade)
- Ausência de autocorrelação
- Normalidade dos resíduos (não obrigatório, mas importante para modelos lineares e muitos testes estatísticos)

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

- Análise dos Resíduos

##### Testes para verificar resíduos como Ruído Branco

Teste de Ljung-Box e gráfico ACF: verificar ausência autocorrelação nos resíduos

Teste Breusch-Pagan, White, ARCH, Gráfico resíduos vs tempo ou valores ajustados: verificar homoscedasticidade de variância nos resíduos

Teste Shapiro-Wilk, Gráfico QQplot, Histograma: verificar normalidade dos resíduos

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Ajuste do Modelo ARMA

#### 4) Validação do Modelo

- Análise dos Resíduos

**Verificação Visual para analisar a autocorrelação**

**ACF/PACF dos Resíduos:** as funções ACF e PACF dos resíduos devem mostrar que todas as autocorrelações estão dentro dos intervalos de confiança indicando que o modelo capturou bem a estrutura da série e efetuou um bom ajuste.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Refinamento do Modelo ARMA

- **Considerando-se o Ajuste do modelo:** se o modelo ARMA ajustado não mostrou-se adequado ao dados será necessário ajustar os valores de  $p$  e  $q$  ou verificar se a série precisa de mais **diferenciações**
- **Considerando-se Modelos Alternativos:** se o modelo ARMA não é suficiente, considere modelos mais complexos, como ARIMA (que inclui diferenciação) ou SARIMA (que inclui sazonalidade).



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Previsão de um Modelo ARMA

Com o modelo ajustado é possível gerar previsões futuras que devem ser acompanhadas de intervalos de confiança para indicar a incerteza das previsões

Compare as previsões com valores futuros observados para verificar a precisão do modelo.

#### Formas de fazer previsões

- Interpolação dos dados
- Extrapolação dos dados

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

#### Interpolação

As previsões são feitas para os pontos não observados dentro do intervalo dos dados observados ou a curto prazo

Dentro do intervalo as **previsões tendem a ser mais confiáveis** porque o modelo tem as informações sobre o comportamento dos dados observados

É importante para fornecer insights a curto prazo ou para um intervalo específico de interesse dentro do intervalo estudado

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

- Razões pelas quais interpolações são valiosas:

- 1) **Planejamento Operacional**

Objetivo: envolve ajustar a produção ou otimizar estoques.

- 2) **Controle e Ajustes de Processos**

Objetivo: manter a consistência e a qualidade para decisões imediatas.

- 3) **Identificação de Tendências e Padrões**

Objetivo: entender comportamentos sazonais ou padrões de curto prazo que informam campanhas de marketing, promoções ou alocação de recursos.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

- Razões pelas quais interpolações são valiosas:

#### 4) Análise de Risco e Planejamento de Contingência

Objetivo: gerenciar riscos financeiros e aproveitar oportunidades de mercado a curto prazo, onde previsões precisas dentro do intervalo de observação são cruciais.

#### 5) Validar Modelos e Hipóteses

Objetivo: testar a robustez de modelos antes de tentar usá-los para extrapolação.

#### 6) Previsão de Séries com Mudanças Estruturais

Objetivo: tomar decisões antes de uma mudança esperada em que extrapolar seria arriscado devido à potencial quebra da estrutura da série.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

**Prazos considerados seguros para interpolações:**

- Previsões de Curtíssimo Prazo  
**Segurança:** Dias ou semanas  
**Contexto:** Gestão de estoque, vendas diárias, demanda de energia
- Previsões de Curto Prazo  
**Segurança:** Algumas semanas a alguns meses  
**Contexto:** Planejamento de produção, alocação de recursos sazonais, previsões econômicas trimestrais

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

**Prazos considerados seguros para interpolações:**

- Previsões de Médio Prazo  
**Segurança:** Varia, mas geralmente até 6 meses  
**Contexto:** Planejamento estratégico, orçamentos, campanhas de marketing baseadas em ciclos sazonais
- Previsões de Longo Prazo  
**Segurança:** não consideradas “seguras” sem reavaliação do modelo  
**Contexto:** Projeções de crescimento econômico, planejamento de grandes investimentos, estratégias de longo prazo em negócios

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

#### Extrapolação

As previsões são feitas para pontos além do intervalo dos dados observados, ou seja, para valores de tempo maiores do que aqueles em estudo.

**Exemplo:** Se você tem dados de vendas mensais de 2010 a 2020 e deseja prever as vendas para 2025, você estaria extrapolando.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

Como melhorar a Extrapolação:

- Incluir Variáveis Externas que influenciam a série temporal.
- Utilizar modelos não lineares como redes neurais, mistura de Gaussianas, etc.
- Atualização contínua do modelo a cada novos dados disponíveis.
- Avaliação do cenário pessimistas, otimistas, e neutros para entender a gama de possíveis resultados.



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

**Desafios da Extrapolação:**

- 1) Maior incerteza:** o modelo pode não capturar adequadamente novos padrões, mudanças de tendência, sazonalidades inesperadas ou eventos externos que influenciam a série após o intervalo observado
- 2) Suposições do Modelo:** assumir que os padrões observados nos dados continuarão da mesma forma no futuro pode não ser verdade se houver mudanças estruturais na série (como mudanças no mercado, novas políticas, etc.)
- 3) Limitações dos Modelos:** fora do intervalo observado as suposições de linearidade e estacionariedade exigidos por alguns modelos em séries temporais podem não se manter, levando a previsões menos precisas.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Previsão de um Modelo ARMA

#### Indicadores de Segurança da Previsão

**Erro de Previsão:** monitorar o erro de previsão ao longo do tempo pode indicar até onde a previsão permanece precisa e calcular métricas como o RMSE (Root Mean Square Error) ou MAE (Mean Absolute Error) para avaliar essa precisão.

**Intervalos de Confiança:** previsões com intervalos de confiança muito amplos indicam maior incerteza, o que pode sinalizar que o horizonte de previsão seguro está sendo excedido

**Reavaliação e Ajuste:** reavaliar o modelo e ajustar as previsões à medida que novos dados se tornam disponíveis pode ajudar a estender o horizonte de previsão de forma mais segura

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Avaliar Erro de Previsão de um Modelo

**RMSE (Root Mean Square Error) ou MAE (Mean Absolute Error)**

São métricas usadas para avaliar o desempenho do modelo

- **Erro quadrático médio (RMSE):** avalia a média dos quadrados das diferenças entre os valores previstos e os valores reais.

$$RMSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

em que  $y_i$  são os valores observados da série original;  $\hat{y}_i$  valores previsto (estimado) pelo modelo;  $n$  número de observações

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Avaliar Erro de Previsão de um Modelo

#### Característica do Erro quadrático médio (RMSE)

- **Sensibilidade a grandes erros:** o RMSE penaliza mais fortemente grandes erros e, por isso, o torna mais sensível a outliers.
- **Diferenciação de modelos:** o RMSE amplifica os maiores erros apontando os modelos com pequenas e grandes falhas.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Avaliar Erro de Previsão de um Modelo ARMA

- **Erro médio absoluto (MAE):** avalia a média das diferenças absolutas entre os valores previstos e os valores reais.

$$RMSE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

em que  $y_i$  são os valores observados da série original;  $\hat{y}_i$  valores previsto (estimado) pelo modelo;  $n$  número de observações

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Avaliar Erro de Previsão de um Modelo

#### Característica do Erro médio absoluto (MAE)

- **Interpretação Intuitiva:** interpretação direta por medir a média dos erros em termos das unidades originais das observações.
- **Robustez a Outliers:** é menos sensível a grandes erros ou outliers em comparação com o MSE.

## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

#### ⇒ Vantagem do Modelo ARMA

- **Simplicidade e eficiência:** é relativamente simples de implementar e entender, o que o torna uma boa escolha para modelar **séries temporais estacionárias** de tamanho moderado.
- **Capacidade de capturar dependências temporais:** consegue capturar dependências temporais complexas na série de dados permitindo previsões mais precisas
- **Aplicabilidade ampla:** pode ser usado em diversas áreas tais como economia, finanças, meteorologia e controle de qualidade desde que os dados sejam estacionários e apresentem dependências temporais.
- **Diagnóstico e ajuste fáceis:** função de autocorrelação (ACF) e a função de autocorrelação parcial (PACF) facilitam a identificação das ordens  $p$  e  $q$  do modelo e a verificação dos resíduos permite um diagnóstico relativamente simples



## 3 Modelagem de Séries Temporais Estacionárias

### 3.1 Modelo Autoregressivo de Média Móvel (ARMA)

⇒ Desvantagem do Modelo ARMA

- **Limitação a Séries Estacionárias:** é adequado somente para séries temporais estacionárias em que a média e a variância são constantes ao longo do tempo.
- **Sensibilidade a Outliers:** por ser sensível a outliers (valores atípicos) a estimação dos parâmetros podem distorcer-se afetando a precisão das previsões.
- **Limitações na Captura de Padrões Não Lineares:** é um modelo linear e pode não ser adequado para capturar padrões não lineares presentes na série temporal.



### 3 Modelagem de Séries Temporais Estacionárias

